



FAKULTA
INFORMATIKY
Masarykova univerzita

Verifikace binarizovaných neuronových sítí pomocí ASP

Obhajoba bakalářské práce

Jindřich Matuška

Obsah

1. Binarizovaná neuronová síť
 - 1.1 Robustnost binarizované neuronové sítě
2. Answer set programming
 - 2.1 Clingo framework
3. Přepis do jazyka Clingo
 - 3.1 Transformace binarizované neuronové sítě pro Clingo
 - 3.2 Kódování v jazyce Clingo
4. Výsledky
 - 4.1 Metodika ohodnocení

Obsah kapitoly 1

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo

4. Výsledky

4.1 Metodika ohodnocení

Binarizovaná neuronová síť

- Hluboká neuronová síť
- Seznam bloků
- Seznam vrstev

Binarizovaná neuronová síť

- Hluboká neuronová síť

- $\mathcal{N} : \mathbb{B}_{\pm 1}^{n_1} \rightarrow \mathbb{N}_0$

- Seznam bloků
- Seznam vrstev

Binarizovaná neuronová síť

- Hluboká neuronová síť

- $\mathcal{N} : \mathbb{B}_{\pm 1}^{n_1} \rightarrow \mathbb{N}_0$

- Seznam bloků

- $\mathcal{N} = t_{d+1} \circ t_d \circ \dots \circ t_1$

- Seznam vrstev

Binarizovaná neuronová síť

- Hluboká neuronová síť

- $\mathcal{N} : \mathbb{B}_{\pm 1}^{n_1} \rightarrow \mathbb{N}_0$

- Seznam bloků

- $\mathcal{N} = t_{d+1} \circ t_d \circ \dots \circ t_1$

- Seznam vrstev

- $t_i : \mathbb{B}_{\pm 1}^{n_i} \rightarrow \mathbb{B}_{\pm 1}^{n_{i+1}}$

- $t_i = t_i^{bin} \circ t_i^{bn} \circ t_i^{lin}$

- $t_{d+1} = t_{d+1}^{am} \circ t_{d+1}^{lin}$

Robustnost binarizované neuronové sítě

- Kvalitativní analýza robustnosti
- Kvantitativní analýza robustnosti
- Oblast vstupů
 - podle Hammingovy vzdálenosti
 - podle pevně zvolených pozic
- Kritérium — počet špatně ohodnocených vstupů
 - $\|\{v \mid v \in R, \mathcal{N}(v) \neq \mathcal{N}(\hat{v})\}\|$

Obsah kapitoly 2

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo

4. Výsledky

4.1 Metodika ohodnocení

Answer set programming

- Deklarativní programovací paradigma
- Vhodné pro prohledávací problémy
- Blízké SAT
 - Logický program

Model (řešení) v ASP

- Logický program
 - $\Pi = \{p \leftarrow p, q \leftarrow \text{not } p\}$
- Redukt programu
- Reprezentant programu $Cn(\Pi)$
- Model

Model (řešení) v ASP

- Logický program
 - $\Pi = \{p \leftarrow p, q \leftarrow \text{not } p\}$
- Redukt programu
 - $\Pi^{\{q\}} = \{p \leftarrow p, q \leftarrow \}$
- Reprezentant programu $Cn(\Pi)$
- Model

Model (řešení) v ASP

- Logický program
 - $\Pi = \{p \leftarrow p, q \leftarrow \text{not } p\}$
- Redukt programu
 - $\Pi^{\{q\}} = \{p \leftarrow p, q \leftarrow \}$
- Reprezentant programu $Cn(\Pi)$
 - Nejmenší uzávěr
 - $Cn(\Pi^{\{q\}}) = \{q\}$
- Model

Model (řešení) v ASP

- Logický program
 - $\Pi = \{p \leftarrow p, q \leftarrow \text{not } p\}$
- Redukt programu
 - $\Pi^{\{q\}} = \{p \leftarrow p, q \leftarrow \}$
- Reprezentant programu $Cn(\Pi)$
 - Nejmenší uzávěr
 - $Cn(\Pi^{\{q\}}) = \{q\}$
- Model
 - $Cn(\Pi^X) = X$

Clingo

- Gringo, Clasp
- Zápis programu
 - Parametricé atomy
- Grounding — převod do mezijazyka aspif
 - Zakódování parametrů
- Solving — hledání řešení
 - Zařezávání větví
 - Conflict driven nogood learning
 - Nutnost projít všechna řešení

Obsah kapitoly 3

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo

4. Výsledky

4.1 Metodika ohodnocení

Požadavky

- Přesný popis problému
- Kódování pomocí celočíselných parametrů
- Malé množství odvozených atomů

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel
- Analýza funkcí ve vrstvách
- Rozpad na případy podle atributů $\frac{\tilde{\alpha}_j}{\tilde{\sigma}_j}$
- Výstupní blok
- Transformace pomocí jazyka Python

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel
- Analýza funkcí ve vrstvách
 - $t_i^{lin}(\vec{x}) = \langle \vec{x}, \mathbf{W} \rangle + \vec{b}$
 - $t_i^{bn}(\vec{x}) = \vec{\alpha} \cdot \frac{\vec{x} - \vec{\mu}}{\vec{\sigma}} + \vec{\gamma}$
 - $t_i^{bin}(\vec{x}) = \text{sign}_{\pm 1}(\vec{x})$
- Rozpad na případy podle atributů $\frac{\vec{\alpha}_j}{\vec{\sigma}_j}$
- Výstupní blok
- Transformace pomocí jazyka Python

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel
- Analýza funkcí ve vrstvách
 - $y_j = \text{sign}_{\pm 1} \left(\tilde{\alpha}_j \cdot \frac{\langle \tilde{x}, \mathbf{w}_{:,j} \rangle + \tilde{b}_j - \tilde{\mu}_j}{\tilde{\sigma}_j} + \tilde{\gamma}_j \right)$
- Rozpad na případy podle atributů $\frac{\tilde{\alpha}_j}{\tilde{\sigma}_j}$
- Výstupní blok
- Transformace pomocí jazyka Python

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel
- Analýza funkcí ve vrstvách
 - $y_j = \text{sign}_{\pm 1} \left(\tilde{\alpha}_j \cdot \frac{\langle \tilde{\mathbf{x}}, \mathbf{w}_{:,j} \rangle + \tilde{b}_j - \tilde{\mu}_j}{\tilde{\sigma}_j} + \tilde{\gamma}_j \right)$
- Rozpad na případy podle atributů $\frac{\tilde{\alpha}_j}{\tilde{\sigma}_j}$
 - $\frac{\tilde{\alpha}_j}{\tilde{\sigma}_j} > 0$:
 - $\langle \tilde{\mathbf{x}}, \mathbf{w}_{:,j} \rangle + \tilde{b}_j - \tilde{\mu}_j + \frac{\tilde{\sigma}_j}{\tilde{\alpha}_j} \cdot \tilde{\gamma}_j \geq 0$
 - $\mathbf{w}'_{:,j} = \mathbf{w}_{:,j}, \tilde{b}'_j = \left\lfloor \tilde{b}_j - \tilde{\mu}_j + \frac{\tilde{\sigma}_j}{\tilde{\alpha}_j} \cdot \tilde{\gamma}_j \right\rfloor$
 - $\langle \tilde{\mathbf{x}}, \mathbf{w}'_{:,j} \rangle + \tilde{b}'_j \geq 0$
- Výstupní blok
- Transformace pomocí jazyka Python

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel
- Analýza funkcí ve vrstvách
 - $y_j = \text{sign}_{\pm 1} \left(\tilde{\alpha}_j \cdot \frac{\langle \tilde{x}, \mathbf{w}_{:,j} \rangle + \tilde{b}_j - \tilde{\mu}_j}{\tilde{\sigma}_j} + \tilde{\gamma}_j \right)$
- Rozpad na případy podle atributů $\frac{\tilde{\alpha}_j}{\tilde{\sigma}_j}$
 - $\langle \tilde{x}, \mathbf{w}'_{:,j} \rangle + \tilde{b}'_j \geq 0$
- Výstupní blok
- Transformace pomocí jazyka Python

Kódování problému

- Vstup
- Vnitřní bloky
- Oblasti vstupů
- Výstup

Kódování problému

- Vstup
 - $\{on(\theta, 0..K-1)\} :- layer(\theta, K).$
- Vnitřní bloky
- Oblasti vstupů
- Výstup

Kódování problému

- Vstup
- Vnitřní bloky
 - `on(L, N) :-`
 `#sum{ W,I : on(L-1, I), weight(L, I, N, W) } >= B,`
 `bias(L, N, B), not output_layer(L).`
- Oblasti vstupů
- Výstup

Kódování problému

- Vstup
- Vnitřní bloky
- Oblasti vstupů
 - :- #count{ N : not input(N), on(0, N);
 N : input(N), not on(0, N) } > H,
 hamdist(H).
 - :- inpfix(N), on(0, N), not input(N).
 :- inpfix(N), not on(0, N), input(N).
- Výstup

Kódování výstupní vrstvy

```
1 % there is single output
2 1 {output(0..N-1)} 1 :- layer(L, N), output_layer(L).

3 % the sum of another is not higher
4 :- output(N), 0 = 1..M-1, output_layer(L), layer(L, M), 0 != N,
5     #sum{ W, I, this : on(L-1, I), weight(L, I, N, W);
6         -W, I, other : on(L-1, I), weight(L, I, 0, W) } < B0 - BN,
7     bias(L, N, BN), bias(L, 0, B0).

8 % the sum of another is not same or order is not higher
9 :- output(N), 0 = 1..M-1, output_layer(L), layer(L, M), 0 != N,
10    #sum{ W, I, this : on(L-1, I), weight(L, I, N, W);
11        -W, I, other : on(L-1, I), weight(L, I, 0, W) } = B0 - BN,
12    bias(L, N, BN), bias(L, 0, B0),
13    outpre(N, PN), outpre(0, P0), P0 > PN.
```

Obsah kapitoly 4

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo


4. Výsledky

4.1 Metodika ohodnocení


Metodika

- Binarizované sítě natrénované na datasetu MNIST
 - M2 — 100:50:10
 - M3 — 400:100:10
 - M7 — 100:50:20:10
 - M11 — 25:25:25:20:10
- Oblasti vstupů
 - Hammingova vzdálenost 0–4 bity
 - 0, 8, 16, 24 volných bitů
- Timeout
 - 300 s

Závislost času na velikosti vstupní oblasti



Závislost času na počtu chybně určených vstupů



Porovnání s BNNQuanalyst

