



FAKULTA
INFORMATIKY
Masarykova univerzita

Verifikace binarizovaných neuronových sítí pomocí ASP

Obhajoba bakalářské práce

Jindřich Matuška

Obsah

1. Binarizovaná neuronová síť
 - 1.1 Robustnost binarizované neuronové sítě
2. Answer set programming
 - 2.1 Clingo framework
3. Přepis BNN do jazyka Clingo
 - 3.1 Transformace binarizované neuronové sítě pro Clingo
 - 3.2 Kódování v jazyce Clingo
4. Výsledky
 - 4.1 Metodika ohodnocení
 - 4.2 Naměřené časy ohodnocení

Obsah

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis BNN do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo


4. Výsledky

4.1 Metodika ohodnocení

4.2 Naměřené časy ohodnocení

Binarizovaná neuronová síť

- Hluboká neuronová síť



- Perceptron
- Argmax vrstva

Binarizovaná neuronová síť

- Hluboká neuronová síť
- Perceptron

$$p = H \circ \xi, \hat{p} = H \circ \rho \circ \xi$$

$$\xi(\vec{x}) = b + \sum_i w_i \cdot x_i, \quad b \in \mathbb{R}, w_i \in \mathbb{B}$$

$$\rho(x) = \alpha \cdot \left(\frac{x - \mu}{\sigma} \right), \quad H(x) = \begin{cases} 1 & x \geq 0 \\ -1 & \text{jinak} \end{cases}$$

- Argmax vrstva

Robustnost funkce

- Kvantitativní definice robustnosti
 - Hodnocená funkce $F : P \rightarrow Q$
 - Oblast vstupů $I \subseteq P$
 - Funkce vah vstupů $w : P \rightarrow \mathbb{R}$, $\forall x \in I : w(x) > 0$
 - Hodnotící funkce $h_p : Q \rightarrow [0, 1]$, $h_p(F(p)) = 0$

$$Q_{w,h_p}(I) = \frac{\sum_{i \in I} w(i) \cdot h_p(F(i))}{\sum_{i \in I} w(i)}$$

- Kvalitativní definice robustnosti

$$Q_{w,h_p}(I) = 0 \iff \forall i \in I. h_p(F(i)) = 0$$

Oblasti vstupů

- Oblast vstupů
 - podle Hammingovy vzdálenosti r

$$R(\vec{x}, r) = \{\vec{u} \mid HD(\vec{x}, \vec{u}) \leq r\}$$

$$\|R(\vec{x}, r)\| = \sum_{i=0}^r \binom{n_0}{i}$$

- podle pevně zvolených pozic $F \subseteq \{1, \dots, n_0\}$

$$R(\vec{x}, F) = \{\vec{u} \mid \forall i \in F. x_i = u_i\}$$

$$\|R(\vec{x}, F)\| = 2^{n_0 - \|F\|}$$

Obsah

1. Binarizovaná neuronová síť

1.1 Robustnost binarizované neuronové sítě

2. Answer set programming

2.1 Clingo framework

3. Přepis BNN do jazyka Clingo

3.1 Transformace binarizované neuronové sítě pro Clingo

3.2 Kódování v jazyce Clingo

4. Výsledky

4.1 Metodika ohodnocení

4.2 Naměřené časy ohodnocení

Answer set programming

- Deklarativní programovací paradigma
- Vhodné pro prohledávací problémy
- Pravidla ve formě
 - $l_0 \text{ or } \dots \text{ or } l_k \leftarrow l_{k+1}, \dots, l_m, \text{ not } l_{m+1}, \dots, \text{ not } l_n.$
- Klasická negace (součást literálu) $\neg$ vs. negace jako selhání not
- Konzistence parciální interpretace s pravidlem

Clingo framework

- Gringo, Clasp
- Rozšíření ASP
 - Parametrizované atomy a pravidla (pouze celočíselné parametry)
 - Agregátní funkce nad množinami (součet, počet, maximum, ...)
- Grounding — převod do mezijazyka aspif
 - Jazyk bez parametrů
 - Každý **možný** literál reprezentuje unikátní přirozené číslo
- Solving — hledání řešení
 - Zařezávání větví
 - Nutnost projít všechna řešení (enumerace modelů)

Obsah

1. Binarizovaná neuronová síť
 - 1.1 Robustnost binarizované neuronové sítě
2. Answer set programming
 - 2.1 Clingo framework
3. Přepis BNN do jazyka Clingo
 - 3.1 Transformace binarizované neuronové sítě pro Clingo
 - 3.2 Kódování v jazyce Clingo
4. Výsledky
 - 4.1 Metodika ohodnocení
 - 4.2 Naměřené časy ohodnocení

Transformace neuronové sítě

- Kódování BNN pomocí celých čísel

$$(H \circ \rho \circ \xi)(\bar{x}) \equiv \alpha \cdot \left(\frac{b + \sum_{i=1}^k w_i \cdot x_i - \mu}{\sigma} \right) + \gamma \geq 0$$

$$b' = \pm \left(-b + \mu - \frac{\sigma \cdot \gamma}{\alpha} \right), \tilde{w}' = \pm \tilde{w}$$

$$(H \circ \rho \circ \xi)(\bar{x}) \equiv \sum_{i=1}^k w'_i \cdot x_i \geq \lfloor b' \rfloor$$

- Výstupní blok
- Transformace pomocí jazyka Python

Kódování problému

- Oblast vstupů

- Hamingova vzdálenost

```
{on(0, 1..N)} :- layer(0, N).
```

```
:- #count { N : not input(N), on(0, N);
```

```
           N : input(N), not on(0, N) } > H,
```

```
    hamdist(H).
```

- Fixní hodnoty pozic

```
on(0, N) :- input(N), infix(N).
```

```
{on(0, K)} :- not infix(K), layer(0, N), K=1..N.
```

- Vnitřní vrstvy

- Výstupní vrstva

Kódování problému

- Oblast vstupů
- Vnitřní vrstvy
 - Bez ukládání mezivýsledků $\xi(\vec{x})$

`on(L, N) :-`

```
#sum{W,I: on(L-1, I), weight(L, I, N, W)} >= B,  
bias(L, N, B), not output_layer(L).
```

- Výstupní vrstva



Kódování problému

- Oblast vstupů
 - Vnitřní vrstvy
 - Výstupní vrstva
 - Zneplatnění modelů s očekávaným výstupem
- : - `output(3)`.



Obsah

1. Binarizovaná neuronová síť
 - 1.1 Robustnost binarizované neuronové sítě
2. Answer set programming
 - 2.1 Clingo framework
3. Přepis BNN do jazyka Clingo
 - 3.1 Transformace binarizované neuronové sítě pro Clingo
 - 3.2 Kódování v jazyce Clingo
4. Výsledky
 - 4.1 Metodika ohodnocení
 - 4.2 Naměřené časy ohodnocení

- Model 100:50:20:10, hammingova vzdálenost 2



- Model 25:25:25:20:10, hammingova vzdálenost 8




Metodika


- Ohodnocení na modelech předtrénovaných na datasetu MNIST
 - Průměr z 3 lepších měření ze 4
1. Výběr nejlepších komponent (M1, M2, M7; M4, M5, M7)
 2. Ohodnocení času pro verifikaci všech modelů na základě různě velkých oblastí vstupů

Model	Architektura	Model	Architektura
M1	100:100:10	M7	100:50:20:10
M2	100:50:10	M8	16:25:20:10
M3	400:100:10	M9	36:15:10:10
M4	64:10:10	M10	16:64:32:20:10
M5	784:100:10	M11	25:25:25:20:10
M6	100:100:50:10	M12	784:50:50:50:50:10

Hammingova vzdálenost $r = 0, 1, 2, 3, 4$



Fixní hodnoty pozic $\|F\| = n_0 - 0, 4, 8, 12, 16, 20, 24$



Diskuze

Robustnost funkce

- Kvantitativní definice robustnosti
 - Hodnocená funkce $F : P \rightarrow Q$
 - Oblast vstupů $I \subseteq P$
 - Funkce vah vstupů $w : P \rightarrow \mathbb{R}$, $\forall x \in I : w(x) > 0$
 - Hodnotící funkce $h_p : Q \rightarrow [0, 1]$, $h_p(F(p)) = 0$

$$Q_{w,h_p}(I) = \frac{\sum_{i \in I} w(i) \cdot h_p(F(i))}{\sum_{i \in I} w(i)}$$

- Striktní hodnotící funkce $\bar{h}_p(q) = \begin{cases} 0 & F(p) = q \\ 1 & F(p) \neq q \end{cases}$

ZARBA, Calogero G. *Many-Sorted Logic*. 2006.

Definition

Let Σ be a signature. The set of Σ -TERMS of sort σ is the smallest set of expressions satisfying the following properties:

- Each variable x of sort σ is a term of sort σ , provided that $\sigma \in \Sigma^S$.
- Each constant symbol $c \in \Sigma^C$ of sort σ is a Σ -term of sort σ .
- If $f \in \Sigma^F$ is a function symbol of arity $\sigma_1 \times \dots \times \sigma_n \rightarrow \sigma$ and t_i is a Σ -term of sort σ_i , for $i = 1, \dots, n$, then $f(t_1, \dots, t_n)$ is a term of sort σ .

Klasická negace pro kódování robustnosti

Symbol on

on(L, N) :-

```
-B <= #sum{
    W,M :      on(L-1, M), weight(L, M, N, W);
    -W,M : not on(L-1, M), weight(L, M, N, W) },
bias(L, N, B).
```

on(L, N) :-

```
-B <= #sum{
    W,M : on(L-1, M), weight(L, M, N, W);
    -W,M : -on(L-1, M), weight(L, M, N, W) },
bias(L, N, B).
```

-on(L, N) :-

```
-B > #sum{
    W,M : on(L-1, M), weight(L, M, N, W);
    -W,M : -on(L-1, M), weight(L, M, N, W) },
bias(L, N, B).
```